

การจำแนกประเภทข้าวหอมมะลิ 105

HomMali 105 Rice Classification

ธนพร ศรีสุโข

สาขาวิชาวิศวกรรมคอมพิวเตอร์ คณะเทคโนโลยีดิจิทัล สถาบันเทคโนโลยีจิตรลดา

บทคัดย่อ

งานวิจัยนี้ได้พัฒนาระบบจำแนกประเภทเมล็ดข้าวหอมมะลิ 105 (HomMali105) กับเมล็ดข้าวพันธุ์อื่น ๆ (กข61, กข41, กข111, กข49, และกข85) โดยประยุกต์ใช้เทคนิคด้านการประมวลผลภาพ Machine Learning เพื่อเพิ่มความแม่นยำและลดข้อจำกัดของการคัดแยกด้วยแรงงานมนุษย์ ระบบที่พัฒนาขึ้น โดยชุดข้อมูลถูกจัดเตรียมจากภาพถ่ายเมล็ดข้าวจริงทั้งแบบวางห่างและวางชิดกัน และแบ่งข้อมูลสำหรับการฝึก ทดสอบ ประกอบด้วย 3 ขั้นตอนหลัก ได้แก่ (1) การตรวจจับตำแหน่งเมล็ดข้าวในภาพด้วยโมเดล YOLOv8 (2) การแบ่งส่วน และครอปเมล็ดข้าวแต่ละเมล็ดด้วย Segment Anything Model (SAM) และทำการปรับขนาดภาพเป็น 224x224 พิกเซล และ (3) การจำแนกประเภทแบบ Binary Classification ด้วยโมเดล Convolutional Neural Network (CNN) โดยใช้ฟังก์ชัน Sigmoid และกำหนดค่า Threshold เพื่อควบคุมการตัดสินใจผลลัพธ์ โดยผลการวิจัยพบว่าเมื่อกำหนดค่า Threshold ที่ 0.47 โมเดลมีความแม่นยำ (Accuracy) บนชุดทดสอบเท่ากับ 0.8087 ทำให้ช่วยเพิ่มค่า Recall แต่ลดค่า Precision ของ Mali105 ในขณะที่ Threshold ที่ 0.57 โมเดลมีความแม่นยำ (Accuracy) บนชุดทดสอบเท่ากับ 0.7869 ทำให้ช่วยเพิ่มค่า Precision แต่ลดค่า Recall ของ Mali105 แสดงให้เห็นถึงความสัมพันธ์เชิงแลกเปลี่ยนระหว่างความแม่นยำและความครอบคลุมของการตรวจจับ นอกจากนี้ยังได้พัฒนาเว็บแอปพลิเคชันเพื่อประยุกต์ใช้งาน โมเดลที่พัฒนาขึ้นจริง โดยเปิดให้ผู้ใช้สามารถปรับค่า Threshold ตามวัตถุประสงค์การใช้งาน

คำสำคัญ : YOLOv8 Convolutional Neural Network (CNN) Segment Anything Model (SAM)

1) บทนำ


ข้าวเป็นพืชเศรษฐกิจที่มีความสำคัญอย่างยิ่งต่อประเทศไทย ทั้งในด้านการบริโภคภายในประเทศและการส่งออก โดยเฉพาะข้าวหอมมะลิ 105 ซึ่งเป็นพันธุ์ข้าวที่มีคุณภาพสูงและเป็นที่ต้องการของตลาดโลก อย่างไรก็ตาม กระบวนการคัดแยกและตรวจสอบพันธุ์ข้าวในปัจจุบันยังคงอาศัยแรงงานมนุษย์และประสบการณ์ของผู้เชี่ยวชาญเป็นหลัก ซึ่งอาจก่อให้เกิดความคลาดเคลื่อน ใช้เวลานาน และไม่สามารถรองรับปริมาณข้อมูลจำนวนมาก ได้อย่างมีประสิทธิภาพ ดังนั้น การนำเทคโนโลยีด้านการประมวลผลภาพ และปัญญาประดิษฐ์มาประยุกต์ใช้จึงเป็นแนวทางที่มีศักยภาพในการเพิ่มความแม่นยำและประสิทธิภาพในกระบวนการดังกล่าว ซึ่งงานวิจัยนี้ได้ใช้

เทคนิคด้าน Machine Learning โดยเฉพาะแบบจำลอง Convolutional Neural Network (CNN) ได้รับความนิยมอย่างแพร่หลายในงานด้านการจำแนกภาพ เนื่องจากสามารถเรียนรู้คุณลักษณะเชิงลึกของวัตถุจากข้อมูลภาพได้อย่างมีประสิทธิภาพ โดยจะใช้ Classify แบบ Binary Classification เพื่อจำแนกพันธุ์ข้าวหอมมะลิ105 และพันธุ์ข้าวอื่น ๆ เช่น พันธุ์กข61, กข41, กข111, กข49, กข85 จากในภาพที่มีทั้งแบบเมล็ดเดี่ยว ๆ ในภาพ ทั้งแบบมีหลาย ๆ เมล็ดในภาพแบบวางห่างกันและชิดกัน และทำเว็บ แอปพลิเคชันการจำแนกเมล็ดพันธุ์ข้าวมาเพื่อใช้ Deploy กระบวนการ Image Processing และโมเดล CNN ในงานวิจัยนี้ โดยกระบวนการ Preprocess ก่อนที่จะได้ผลลัพธ์การ Classify ออกมาคือการใช้ YOLOv8 ตรวจจับเมล็ดข้าวในภาพว่ามีกี่เมล็ด อยู่ตำแหน่งไหน จากนั้นก็ครอปเมล็ดข้าวแต่ละเมล็ดโดยใช้โมเดล Segment Anything Model (SAM) แล้วก็ทำ padding รอบ ๆ ขอบรูปร่างเมล็ดข้าว ทำพื้นหลังให้เป็นสีดำ แล้วค่อยส่งเข้าโมเดล CNN ซึ่งจะมีการ resize ภาพให้ได้ 224x224 pixel เพื่อ Classify ผลลัพธ์ออกมาว่าเมล็ดข้าวนั้นเป็นพันธุ์หอมมะลิ 105 หรือพันธุ์อื่น ๆ อย่างไรก็ตาม ความแม่นยำของการจำแนกภาพไม่ได้ขึ้นอยู่กับแบบจำลองเพียงอย่างเดียวแต่ยังขึ้นอยู่กับคุณภาพของข้อมูลนำเข้า โดยเฉพาะขั้นตอนการถ่ายภาพ ลักษณะการตรวจจับวัตถุ การแบ่งส่วนภาพ และการเตรียมข้อมูลภาพก่อนนำไปฝึกหรือทดสอบแบบจำลอง

2) เอกสารที่เกี่ยวข้อง

2.1) ทฤษฎีที่เกี่ยวข้อง

2.1.1) Convolutional Neural Network (CNN)



รูปที่ 1 Convolutional Neural Network Architecture

Convolutional Neural Network (CNN) หรือ โครงข่ายประสาทแบบคอนโวลูชัน เป็นโครงข่ายประสาทเทียมหนึ่งในกลุ่ม bio-inspired โดยที่ CNN จะจำลองการมองเห็นของมนุษย์ที่มองเห็นพื้นที่ที่น้อยๆ และนำกลุ่มของพื้นที่ที่น้อยๆ มาผสานกัน เพื่อดูว่าสิ่งที่เห็นอยู่เป็นอะไร

แนวคิดของ CNN ต้องมีคณิตศาสตร์มารองรับ โดยการคำนวณตามแนวคิดนี้ใช้หลักการเดียวกันกับ คอนโวลูชันเชิงพื้นที่ (Spatial Convolution) ในการทำงานด้าน Image Processing การคำนวณนี้จะเริ่มจากการกำหนดค่าใน ตัวกรอง (filter) หรือเคอร์เนล (kernel) ที่ช่วยดึงคุณลักษณะที่ใช้ในการรู้จำวัตถุออก โดยปกติตัวกรอง/เคอร์เนลอันหนึ่งจะดึงคุณลักษณะที่สนใจออกมาได้หนึ่งอย่าง เราจึงจำเป็นต้องตัวกรองหลายตัวกรองด้วย เพื่อหาคุณลักษณะทางพื้นที่หลายอย่างประกอบกัน และมี Stride เป็นตัวกำหนดว่าเราจะเลื่อนตัวกรอง (filter) ไปด้วย Step เท่าไร สามารถกำหนดค่าของ Stride ให้มากขึ้นก็ได้ ถ้าเราต้องการให้การคำนวณหาคุณลักษณะมีพื้นที่ที่ทับซ้อนกันน้อยขึ้น แต่อย่างไรก็ตามการกำหนดค่าของ Stride ที่มากขึ้นจะทำให้เราได้ฟังก์ชันคุณลักษณะ (feature map) ที่มีขนาดเล็กลง และมี Padding เติมเข้าไปรอบๆพื้นที่ของ Input โดยอาจจะเป็นเติม 0 หรือค่าต่างๆเข้าไป เพื่อให้เวลาในการทำ CNN นั้น Feature Map ที่ได้ยังคงมีขนาดเท่ากับ Input เพื่อแก้ปัญหา Input ที่อยู่ตามขอบภาพอาจมีความสำคัญที่ส่งผลต่อการตัดสินใจบางอย่าง จึงจำเป็นต้องเก็บคุณลักษณะตามขอบของรูปภาพไว้ จากนั้นก็ส่งไป Max Pooling เป็นตัวกรองแบบหนึ่งที่ทำค่าสูงสุดในบริเวณที่ตัวกรองทาบอยู่มาเป็นผลลัพธ์ โดยจะต้องเตรียมตัวกรองในลักษณะเดียวกับการทำ Feature Extraction ของ CNN มาทาบบนข้อมูลแล้วเลือกค่าที่สูงที่สุดบนตัวกรองนั้นมาเป็นผลลัพธ์ใหม่ และจะเลื่อนตัวกรองไปตาม Stride ที่กำหนดไว้ โดยขนาดตัวกรองของการทำ max pooling จะนิยมเรียกกันว่า pool size ขณะที่ตัวกรองเคลื่อนที่ไปตามอินพุตมันจะคำนวณค่าเฉลี่ยภายในขอบเขตการรับรู้เลือกค่าที่สูงที่สุดภายในขอบเขตของตัวกรองเพื่อส่งไปยังอาร์เรย์ Output ต่อไปเป็น Fully-connected layer เป็นเลเยอร์เชื่อมต่อแบบเต็ม โหนดแต่ละโหนดในเลเยอร์ Output จะเชื่อมต่อโดยตรงกับโหนดในเลเยอร์ก่อนหน้า ชั้นนี้ทำหน้าที่จำแนกประเภทโดยอาศัยคุณลักษณะที่สกัดได้จากชั้นก่อนหน้าและตัวกรองต่างๆ ส่วนในกรณีงานวิจัยนี้ที่เป็นการจำแนกแบบ 2 คลาส (Binary Classification) ชั้น Output จะนิยมใช้ฟังก์ชัน Sigmoid คำนวณแยกกันทีละคลาส และ Output จะให้ค่าอยู่ในช่วง 0-1 และก่อนเข้าสู่กระบวนการ Convolution ได้มีการทำ Data Augmentation เพื่อเพิ่มความหลากหลายของข้อมูลและลดปัญหา overfitting คือการทำ RandomFlip (การสุ่มพลิกกลับด้าน) และ RandomRotation (การหมุนภาพแบบสุ่ม)

2.1.2) YOLOv8

YOLOv8 ถูกเผยแพร่โดยบริษัท Ultralytics เมื่อวันที่ 10 มกราคม ค.ศ. 2023 โดยมีประสิทธิภาพที่โดดเด่นทั้งในด้านความแม่นยำและความเร็วจากการพัฒนาต่อยอดจากความก้าวหน้าของ YOLO รุ่นก่อนหน้า โดย YOLOv8 มีคุณสมบัติใหม่และการปรับปรุงประสิทธิภาพหลายประการ ดังนั้นชุดโมเดลของ YOLOv8 จะมีความหลากหลาย โดยแต่ละโมเดลถูกออกแบบมาเฉพาะสำหรับงานด้านคอมพิวเตอร์วิทัศน์ที่แตกต่างกัน ตั้งแต่งานตรวจจับวัตถุ (Object Detection) ไปจนถึงงานที่มีความซับซ้อนมากขึ้น เช่น การแบ่งส่วนวัตถุเชิงตัวอย่าง (Instance Segmentation) การตรวจจับท่าทางหรือจุดสำคัญของร่างกาย (Pose/Keypoints Detection) การตรวจจับวัตถุแบบมีทิศทาง (Oriented Object Detection) และการจำแนกประเภท (Classification) อีกทั้งยังรองรับโหมดการทำงานที่หลากหลาย ได้แก่ การ

อนุมานผล (Inference) การตรวจสอบความถูกต้องของโมเดล (Validation) การฝึกสอนโมเดล (Training) และการส่งออกโมเดล (Export) ซึ่งเอื้อต่อการนำไปใช้งานในขั้นตอนต่างๆ ของการพัฒนาและการใช้งานจริง ในส่วนของงานวิจัยนี้จะใช้ YOLOv8 เพื่อสร้างกรอบที่ตรวจจับเมล็ดข้าวในภาพ

2.1.3) Segment Anything Model (SAM)

Segment Anything Model (SAM) เป็นโมเดลสำหรับการแบ่งส่วนภาพ (Image Segmentation) ที่มีความก้าวหน้าทันสมัย โดยรองรับการแบ่งส่วนภาพแบบกำหนดเงื่อนไขด้วยคำสั่ง (promptable segmentation) ซึ่งมอบความยืดหยุ่นสูงในการวิเคราะห์ภาพ

SAM ถือเป็นแกนกลางของโครงการ Segment Anything ซึ่งเป็นโครงการเชิงนวัตกรรมที่นำเสนอโมเดล งาน และชุดข้อมูลรูปแบบใหม่สำหรับการแบ่งส่วนภาพ ด้วยโครงสร้างขั้นสูงของ SAM ทำให้โมเดลสามารถปรับตัวให้เข้ากับการกระจายของข้อมูลภาพและงานใหม่ ๆ ได้โดยไม่ต้องมีความรู้ล่วงหน้า ซึ่งคุณสมบัตินี้เรียกว่า การถ่ายโอนความรู้แบบศูนย์ตัวอย่าง (Zero-shot Transfer) โดย SAM ได้รับการฝึกสอนด้วยชุดข้อมูล SA-1B ซึ่งประกอบด้วยหน้ากากภาพ (masks) มากกว่า 1 พันล้านรายการ จากภาพที่ผ่านการคัดเลือกว่ามีคุณภาพกว่า 11 ล้านภาพ ส่งผลให้ SAM แสดงประสิทธิภาพแบบ zero-shot ได้อย่างโดดเด่น และในหลายกรณีสามารถให้ผลลัพธ์ที่ดีกว่าวิธีการเรียนรู้แบบมีผู้สอนเต็มรูปแบบ (Fully Supervised Learning) ที่เคยมีมาก่อน ในส่วนของงานวิจัยนี้จะใช้ SAM เพื่อครอบภาพเมล็ดข้าวตามขอบรูปร่างของเมล็ดข้าว หลังจากที่ใช้ YOLOv8 ตรวจจับภาพเมล็ดข้าวแล้ว

2.1.4) Roboflow

Roboflow เป็นเครื่องมือที่ใช้ในการพัฒนาและฝึกโมเดล Computer Vision โดยให้ความสำคัญกับการสร้างชุดข้อมูลภาพเพื่อใช้ในการฝึกโมเดล ในงานวิจัยนี้จะใช้ Roboflow กับภาพ โดยการ Annotate เมล็ดข้าวในภาพและตั้งชื่อให้กับ Label ของเมล็ดข้าว เพื่อใช้เตรียมภาพสำหรับนำไปฝึกโมเดล YOLOv8 เพื่อให้โมเดลสามารถตรวจจับเมล็ดข้าวได้

2.2) งานวิจัยที่เกี่ยวข้อง


บทความงานวิจัยที่ได้ค้นคว้ามาจะประยุกต์ใช้วิธีการตรวจหาวัตถุด้วยตัวแบบ YOLOv5 มาช่วยในการจำแนกพันธุ์ข้าวจากภาพของเมล็ดข้าวสารของพันธุ์ข้าวการากาด หอมมะลิ ยิปซาลา บาสมาดี และอาโบริโอ การดำเนินการวิจัยได้แบ่งเป็นสามส่วนหลัก ได้แก่ การดำเนินการด้านวิศวกรรมข้อมูล ซึ่งเป็นการพัฒนาโปรแกรมด้วยภาษาไพทอนเพื่อใช้ในการจัดเตรียมข้อมูลเพื่อให้ระบบปัญญาประดิษฐ์เรียนรู้ การดำเนินการด้านวิทยาการข้อมูลโดยใช้โปรแกรมภาษาไพทอนร่วมกับระบบประมวลผล Google Colaboratory ทำการตรวจหาเมล็ดข้าวสาร และออกแบบการประเมินความแม่นยำของตัวแบบ ในส่วนของงานจัดเตรียมข้อมูลได้นำรูปเมล็ดข้าวเมล็ดเดี่ยวชนิดเจแปกจาก <https://www.muratkoklu.com/datasets/> มาทำการลดสัญญาณรบกวน กำจัดพื้นหลัง และแปลงเป็นภาพชนิดพีเอ็นจี แล้วนำมาใส่ในภาพขนาด 800 x 800 จุดภาพ จำนวนภาพละ 20-64 เมล็ด โดยมีทั้งรูปแบบไม่มีภาพเมล็ดข้าวสารซ้อนทับกัน มีภาพเมล็ดข้าวสารซ้อนทับกันร้อยละ 5, 10, 15, 20 และ 25 จากนั้นนำภาพที่ไม่มีเมล็ดข้าวสาร

ซ้อนทับกัน ไปฝึกตัวแบบ YOLOv5 แล้วใช้ ตัวแบบดังกล่าวจำแนกพันธุ์ข้าวและระบุตำแหน่งต่าง ๆ ของเมล็ดข้าวสารที่ปรากฏในภาพ ผลการวิจัยพบว่าตัวแบบ YOLOv5 สามารถ จำแนกพันธุ์ข้าวของเมล็ดข้าวสารทั้ง 5 สายพันธุ์ได้ดี โดยการประเมินความแม่นยำของตัวแบบที่ค่าขีดแบ่ง 0.6 พบว่าตัวแบบสามารถ จำแนกพันธุ์ข้าวที่ปรากฏในภาพที่มีภาพเมล็ดข้าวสารซ้อนทับกันร้อยละ 0, 5, 10, 15, 20 และ 25 ได้ถูกต้องร้อยละ 99.13, 99.00, 98.62, 98.19, 97.56 และ 96.89 ตามลำดับ

ส่วนในกรณีของงานวิจัยนี้จะเป็นการใช้ YOLOv8 ในการตรวจจับเมล็ดข้าวและใช้ SAM เพื่อครอบภาพเมล็ดข้าวตามขอบรูปร่างของเมล็ดข้าวแล้วที่ใช้โมเดล CNN จำแนกผลลัพธ์ว่าเมล็ดไหนเป็นข้าวพันธุ์หอมมะลิ 105 หรือข้าวพันธุ์อื่นๆ และทำแอปพลิเคชันขึ้นมาเพื่อใช้งานการจำแนกผลพันธุ์ข้าวจากโมเดล CNN โดยโมเดลจะใช้ค่า Threshold ในการตัดสินใจผลลัพธ์การจำแนก

3.) วิธีดำเนินการวิจัย

Flow Chart การดำเนินงาน



3.1) ดำเนินการถ่ายภาพเมล็ดข้าว

ในการถ่ายภาพจะไม่มีการจัดแสงระหว่างถ่ายภาพ จะใช้แสงจริงในแต่ละช่วงเวลาของสภาพแวดล้อมที่ถ่ายภาพ ซึ่งก็ต้องมีความสว่าง และเห็นขอบเมล็ดข้าว สีของเมล็ดข้าวได้อย่างชัดเจน จากนั้นก็วางกระดาสีขาวไว้บน โต๊ะไว้เพื่อเป็นพื้นหลังรองเมล็ดข้าว ซึ่งสีขาวก็เป็นสิ่งที่ทำให้เมล็ดข้าวดูเด่นขึ้นมา แล้วก็วางแผ่นพลาสติกใสทับกระดาสีขาว จากนั้นก็วางเมล็ดข้าวทั้ง 6 พันธุ์ไว้บนแผ่นพลาสติกใส มีเมล็ดข้าวพันธุ์กข61, กข 111, กข41, กข85, กข49 และหอมมะลิ 105 โดยจะวางพันธุ์หอมมะลิ 105 ไว้แถวบน ส่วนพันธุ์อื่น ๆ ที่เหลือจะวางไว้แถวล่างถัดลงมา และในภาพก็จะมีเมล็ดข้าวอยู่ประมาณ 10-12 เมล็ด โดยจัดวางให้เมล็ดข้าวเรียงห่างกัน ถ่ายเป็นชุดไว้ให้ได้ประมาณ 70 ภาพขึ้นไป และถ่ายภาพเมล็ดข้าวแบบเรียงชิดติดกันเป็นชุดไว้ประมาณ 70 ภาพขึ้นไปเช่นเดียวกัน และเนื่องจากต้องการที่จะถ่ายภาพเมล็ดข้าวให้เก็บได้หมดทุกเมล็ดตามที่ต้องการ แต่ภาพยังต้องมีความชัดเจน จึงได้ใช้มือถือในการถ่ายภาพ โดยจะใช้กล้องหลังของมือถือ ใช้เป็นโหมดการถ่ายภาพธรรมดาแล้วใช้การซูม x2 ซึ่งก็จะเก็บภาพเมล็ดข้าวได้ทุกเมล็ด และยังมีภาพชัดเจน



รูปที่ 2 เมล็ดห่างกัน

รูปที่ 3 เมล็ดติดกัน

3.2) การเตรียมภาพเมล็ดข้าวเพื่อใช้ฝึก YOLOv8

อัปโหลดภาพถ่ายเมล็ดข้าวเข้าไปในเครื่องมือ Instance Segmentation ของ Roboflow เพื่อทำ Segmentation ภาพเมล็ดข้าว แยกจาก Background โดยการทำ Annotate ให้กับภาพเมล็ดข้าวแต่ละเมล็ด แล้วตั้งชื่อ Label ว่า “rice”



รูปที่ 4 การ Annotate ภาพเมล็ดข้าว

เมื่อทำครบทุกภาพทั้งภาพชุดแบบเมล็ดข้าวห่างกัน และแบบติดกัน แล้ว ก็แบ่งภาพการ train, valid, และ test เป็น 90 %, 5 %, และ 5 % ตามลำดับ จากนั้นทำการ resize ภาพเป็นแบบ Fit- within 640x640 และทำการ Augmentations เพื่อเพิ่มจำนวนภาพเมล็ดข้าวให้มีความหลากหลาย ซึ่งจะทำให้ได้ชุดภาพ train 669 ภาพ, valid 29 ภาพ, และ test 29 ภาพ แล้วสุดท้ายจึง Download Dataset ทั้งหมดเป็นไฟล์ YOLOv8.zip เพื่อที่จะนำ Dataset ไปใช้ฝึก YOLOv8 ต่อไป

3.3) การฝึกโมเดล YOLOv8 เพื่อใช้ตรวจจับเมล็ดข้าว

ในการฝึกโมเดล YOLOv8 จะดำเนินการโดยใช้การเขียนโค้ดภาษา Python เริ่มจากการ pip install ultralytics เพื่อนำตัวโมเดล yolov8.pt มาเพื่อใช้ฝึกด้วย Dataset ภาพเมล็ดข้าวที่โหลดมาจาก Roboflow ซึ่งจะใช้ไฟล์ data.yaml ใช้ค่า epochs = 20, image_size = 640, และ batch_size = 8 เมื่อดำเนินการแล้วก็ได้ไฟล์โมเดลที่ถูกฝึกเสร็จแล้วชื่อว่า best.pt จะเป็นไฟล์จากโมเดล YOLOv8 ที่จะใช้ในการตรวจจับเมล็ดข้าว

3.4) กระบวนการเตรียมภาพก่อนเข้าฝึกโมเดล CNN

กระบวนการนี้จะใช้ไฟล์ best.pt ของ YOLOv8 ช่วยตรวจจับจำนวนและตำแหน่งของเมล็ดข้าวในภาพก่อน จากนั้นก็เป็นการแยกคลาสเมล็ดข้าวดำเนินการโดยอาศัยตำแหน่งเชิงพื้นที่ในแนวแกน y ของกรอบล้อมที่ได้จากการตรวจจับด้วย YOLOv8 โดยนำค่าพิกัดกึ่งกลาง (y-center) ไปจัดกลุ่มด้วยอัลกอริทึม K-means (k = 2) เพื่อแบ่งเมล็ดข้าวตามตำแหน่งแถบบนและล่างของภาพ กลุ่มที่มีค่าเฉลี่ยของ y-center ต่ำกว่าจะถูกพิจารณาว่าอยู่บริเวณด้านบนของภาพ ขณะที่กลุ่มที่มีค่าเฉลี่ยของ y-center สูงกว่าจะอยู่บริเวณด้านล่างของภาพ จากนั้นกำหนดเมล็ดข้าวในกลุ่มแถบบนเป็น **คลาส Mali105** และกลุ่มแถบล่างเป็น **คลาส Other** ซึ่งเป็นแนวทางการกำหนด Label ข้อมูลแบบกึ่งอัตโนมัติที่เหมาะสมกับชุดข้อมูลที่มีการจัดวางเชิงโครงสร้างอย่างชัดเจนแล้วจึงใช้โมเดล Segment Anything Model (SAM) ในการครอบภาพเมล็ดข้าวแต่ละเมล็ดตามขอบรูปร่างของเมล็ดข้าวที่ตรวจจับได้ แล้วก็เติม padding ทั้งหมด 200 pixel ให้กับภาพเป็นพื้นหลังสีดำ เพราะพื้นหลังสีดำจะมีความ contrast กับสีเมล็ดข้าวมาก โมเดล CNN จะได้เห็นขอบของเมล็ดข้าวและรายละเอียดของเมล็ดข้าวได้ชัดเจน จากนั้นก็จะเป็นการแบ่งชุดข้อมูล สุ่มภาพที่ได้ทั้งหมด และจัดแบ่งออกเป็นชุด train 80%, validation 10 % และ test 10% จึงทำให้มีจำนวนภาพ train 1521 ภาพ, validation 220 ภาพ, และ test 183 ภาพ เพื่อส่งเข้าฝึกโมเดล CNN



รูปที่ 5 ภาพเมล็ดข้าวที่จะส่งเข้าฝึกโมเดล CNN

3.5) ฝึกโมเดล CNN

หลังจากทำกระบวนการ Preprocess ให้กับภาพเมล็ดข้าวแล้ว จะนำภาพเข้าโมเดล CNN โดยมีการกำหนด Parameter ในโค้ดที่จะใช้ดำเนินการคือ IMG_SIZE = 224x224 (เป็นการ resize ภาพ), BATCH_SIZE = 32, EPOCHS = 20, THRESHOLD = 0.47 (สามารถปรับค่า Threshold ได้ตามกราฟ ROC Curve และกราฟ Score Distribution ที่ใช้ดูค่า Best Threshold ในการ Classify), มีการใส่ Class weight เพื่อให้การแบ่งข้อมูลทั้งสองคลาสที่จะใช้ Classify มีปริมาณใกล้เคียงกัน ลดความ bias ได้, มีใส่ callback เพื่อลด Overfit และลด learning rate เมื่อ val_loss ไม่ดีขึ้น, และใช้ฟังก์ชัน


Sigmoid ในการ Classify คลาส ใช้ค่า Threshold ตัดสินใจว่าจะเป็น 0 คือ Class Other หรือ 1 คือ Class Mali105

4) ผลการวิจัย


กราฟ ROC Curve และ Score Distribution

เนื่องจากโมเดล CNN ให้ผลลัพธ์เป็นค่าความน่าจะเป็น การกำหนดค่า Threshold จึงมีผลต่อความแม่นยำในการจำแนกคลาส ในส่วนนี้จึงนำเสนอกราฟ ROC Curve และการกระจายคะแนนของข้อมูล เพื่อใช้ในการวิเคราะห์และกำหนดค่า Threshold ที่เหมาะสมสำหรับชุดข้อมูล Train และ Test

กราฟ ROC Curve: Train Set




กราฟ Score Distribution: Train Set




ค่า Best Threshold ที่เหมาะสมในการ Classify ข้อมูลภาพ Train Set = 0.579

กราฟ ROC Curve: Test Set



กราฟ Score Distribution: Test Set



ค่า Best Threshold ที่เหมาะสมในการ Classify ข้อมูลภาพ Test Set = 0.473

Classification Report: Train Set ค่า Threshold 0.57

Class	Precision	Recall	F1-score	Support
Other	0.8236	0.8411	0.8322	755
Mali105	0.8400	0.8225	0.8311	766
Accuracy			0.8317	1521

Classification Report: Test Set ค่า Threshold 0.57

Class	Precision	Recall	F1-score	Support
Other	0.8020	0.8100	0.8060	100
Mali105	0.7683	0.7590	0.7636	83
Accuracy			0.7869	183

Confusion Matrix: Test Set ค่า Threshold 0.57

True / Predicted	Other	Mali105
Other	TN = 81	FP = 19
Mali105	FN = 20	TP = 63

Classification Report: Train Set ค่า Threshold 0.47

Class	Precision	Recall	F1-score	Support
Other	0.8804	0.7311	0.7988	755
Mali105	0.7729	0.9021	0.8325	766
Accuracy			0.8172	1521

Classification Report: Test Set ค่า Threshold 0.47

Class	Precision	Recall	F1-score	Support
Other	0.8652	0.7700	0.8148	100
Mali105	0.7553	0.8554	0.8023	83
Accuracy			0.8087	183

Confusion Matrix: Test Set ค่า Threshold 0.47

True / Predicted	Other	Mali105
Other	TN = 77	FP = 23
Mali105	FN = 12	TP = 71

5) สรุปผลการวิจัย

ผลลัพธ์ของการจำแนกเมล็ดพันธุ์ข้าวทั้งสองคลาสขึ้นอยู่กับ การกำหนดค่า Threshold ของโมเดล โดยจากการทดลองบนชุดข้อมูลทดสอบพบว่า ค่า Threshold สูงสุด คือประมาณ 0.47 ส่วนการทดลองบนชุดข้อมูลฝึกพบว่า ค่า Threshold สูงสุด คือประมาณ 0.57 อย่างไรก็ตาม เมื่อพิจารณาผลกระทบของการปรับค่า Threshold พบว่า

- เมื่อกำหนดค่า Threshold ในช่วงน้อยกว่าหรือเท่ากับประมาณ 0.56 ค่า Recall จะสูงกว่าค่า Precision แสดงว่าโมเดลมีแนวโน้มตรวจจับเมล็ดพันธุ์ข้าวหอมมะลิ 105 ได้ในจำนวนมาก (ลด False Negative) แต่อาจมีเมล็ดพันธุ์อื่นถูกจำแนกผิดเป็น Mali105 มากขึ้น (เพิ่ม False Positive) แนวทางนี้เหมาะสำหรับผู้บริโภคที่ต้องการความครอบคลุมในการตรวจจับข้าวหอมมะลิ 105

- เมื่อกำหนดค่า Threshold ตั้งแต่ประมาณ 0.57 ขึ้นไป ค่า Precision จะสูงกว่าค่า Recall แสดงว่าโมเดลมีความมั่นใจสูงว่าตัวอย่างที่จำแนกว่าเป็น Mali105 ส่วนใหญ่เป็นข้อมูลที่ถูกต้อง (ลด False Positive) แต่จะมีการพลาดการตรวจจับบางส่วนของเมล็ด Mali105 (เพิ่ม False Negative) แนวทางนี้เหมาะสำหรับผู้ผลิตที่ต้องการลดความเสี่ยงในการจำแนกข้าวพันธุ์อื่นปะปนเป็นข้าวหอมมะลิ 105

ข้อเสนอแนะ และข้อจำกัด

- ความหลากหลายของสภาพแวดล้อมในการถ่ายภาพยังมีจำกัด จึงสามารถเพิ่มความหลากหลายของชุดข้อมูลภาพได้ โดยการถ่ายภาพในสภาพแสง (ความเข้มแสงต่างกัน), มุมกล้อง (มุมเอียง มุมใกล้-ไกล), และพื้นหลังที่หลากหลาย

- ผลการวิจัยพบว่า การปรับค่า Threshold ส่งผลโดยตรงต่อค่า Precision และ Recall ของโมเดล และไม่สามารถกำหนดค่า Threshold

เดียวที่เหมาะสมกับทุกบริบทได้ เนื่องจากความต้องการของผู้ใช้งานแต่ละกลุ่มแตกต่างกัน

- โมเดล YOLOv8 อาจตรวจจับเงาในภาพถ่ายว่าเป็นเมล็ดข้าวได้

อ้างอิง

- [1] Phongchit, N. (2018). Convolutional Neural Network (CNN) คืออะไร. Medium. Retrieved February 17, 2026, from <https://medium.com/@natthawatphongchit/มาลองดูกันกับ-cnn-กัน-e3f5d73eebaa>
- [2] Ultralytics. (2023). Explore Ultralytics YOLOv8. Ultralytics YOLO Docs. Retrieved February 17, 2026, from <https://docs.ultralytics.com/models/yolov8/>
- [3] Ultralytics. (2023). Segment Anything Model (SAM). Ultralytics Docs. Retrieved February 17, 2026, from <https://docs.ultralytics.com/models/sam/>
- [4] Pinyorattanakit, N. (2023). สร้าง AI ตรวจจับวัตถุในรูปภาพด้วย Roboflow. Medium. Retrieved February 17, 2026, from <https://nattakit-nice2580.medium.com/สร้าง-ai-ทำนายรูปภาพด้วย-roboflow-6bb96a632f4d>
- [5] Roboflow. (n.d.). Roboflow: Computer vision tools for developers and enterprises. Retrieved February 17, 2026, from <https://roboflow.com/>
- [6] Watchararat, W., & Tanthanuch, J. (2023). การจำแนกพันธุ์ข้าวจากภาพของเมล็ดข้าวสารด้วยวิธีการตรวจหาวัตถุ. *Journal of Engineering and Digital Technology (JEDT)*, 11(2), 14-24.